

TP Genómica – Ensamblaje *de novo* del genoma nuclear de *Caenorhabditis elegans*

Este trabajo se desarrollará en **Galaxy Europa** (<https://usegalaxy.eu/>).

Para comenzar, es necesario **registrarse**, activar la cuenta mediante el link que la plataforma les envía por email y luego **iniciar sesión** en la plataforma.

Introducción a Galaxy

Se recomienda revisar el siguiente tutorial introductorio: [Galaxy Introduction \(short tutorial\)](#)


Paso 1. Importar datos

Debido a las limitaciones de tiempo y recursos computacionales, trabajaremos con un **submuestreo** de los datos originales.

- **Archivo utilizado en el TP:** ~3.1 GB
- **Archivo original:** 54.7 GB, correspondiente a una secuenciación de la cepa **CGC1** de *Caenorhabditis elegans* (derivada de la cepa WT de referencia), realizada mediante la plataforma **Oxford Nanopore**.
- **Fuente de los datos:** NCBI, corrida con el identificador [DRR656639](https://www.ncbi.nlm.nih.gov/assembly/DRR656639/).

Este subsampleo nos permitirá realizar los análisis con mayor agilidad, manteniendo la representatividad biológica del experimento original.

Click en Upload (panel izquierdo) y luego click en *New upload Beta* (abajo izquierda)




Luego copiar el siguiente link:

https://usegalaxy.eu/api/datasets/26c75dccc616ac8c51bfc8c5f6df1e8/display?to_ext=fastqsanger.gz

Para eso:

beta upload > Paste Links/URLs > pegar enlace > Add URLs



Cambiar nombre a “celegans” y tipo “fastqsanger.gz”

> *Start* (~1 min)

Import Data ^{Beta} / Paste Links/URLs

Tip: Deferred datasets behave like normal datasets, but are fetched automatically at runtime. It is recommended to set the correct datatype when using deferred mode, as automatic detection is limited for deferred datasets, since the data is not downloaded immediately. < 3 / 4 >

Target history: LR_UBA (current) Choose another

1 URL(s) added

Name	Type	Reference	Upload Settings
celegans	fastqsanger.gz	unspecified (?)	☐ Spaces→Tabs ☐ Deferred

Create a collection from these files [Learn more about dataset collections in Galaxy](#)

+ Add More URLs Clear All

Cancel Start

En el panel derecho, chequear que se cargó completamente el archivo. El ítem pasará de gris a amarillo durante la carga y finalmente será verde cuando se haya cargado correctamente.

Paso 2. Descripción de datos y control de calidad

Para determinar la calidad de los datos obtenidos utilizaremos la herramienta [NanoPlot](#) (2 min):

 **NanoPlot** Plotting suite for Oxford Nanopore sequencing data and alignments (Galaxy Version 1.47.1+galaxy0)

Tool Parameters

Select multifile mode

batch

When supplying multiple files, batch mode will run NanoPlot on each file separately, while combined mode will run on all files together. If you supply a single file, this setting does not matter.

Type of the file(s) to work on

fastq

files *

   ... 1: celegans

accepted formats ▼
(--fastq)

Options for filtering or transforming input prior to plotting

Options for customizing the plots created

Parámetros:

- Type of file = fastq (lo detecta automáticamente)
- Files = “celegans” (lo detecta automáticamente)

Se puede personalizar utilizando los siguientes parámetros opcionales:

Options for filtering or transforming input prior to plotting

Options for customizing the plots created

Specify a color for the plots. - optional

coral

(--color)

Specify the bivariate format of the plots. - optional

☒ Select / Deselect all

☒ kernel density estimation (kde)

☐ dots (dot)


(--plots)

Show the N50 mark in the read length histogram.

☒ Yes

(--N50)

>Run Tool (3 min):



Se obtienen 3 outputs (ver panel de la derecha “History”)

- NanoPlot on dataset 1: HTML report
- NanoPlot on dataset 1: NanoStats
- NanoPlot on dataset 1: NanoStats post filtering


Nota: en este caso “dataset 1” corresponde al número de dataset que nosotros subimos a la historia, pero variará en función del número que le asigne Galaxy.

El archivo HTML report, es un informe visual interactivo que resume la calidad y características de las lecturas de secuenciación. Es un archivo que se abre en un navegador y presenta gráficos y estadísticas. El archivo NanoStats contiene un resumen estadístico de las lecturas de secuenciación.

A partir de la información brindada en estos archivos respondan:

1. ¿Cuál es el número total de lecturas? ¿Y el número total de bases?
2. ¿Se puede estimar la cobertura del genoma? Dato: Tamaño aproximado del genoma de *C. elegans* = ~ 100 Mb.
3. ¿Cuál es la longitud promedio de las lecturas? ¿Cuál es el N50 de las lecturas? ¿Cómo se interpreta?
4. ¿Cuál es la calidad promedio de las lecturas? ¿En qué rango se encuentra?
5. Con base en estos parámetros analizados: ¿consideran que la cantidad, longitud y calidad de las lecturas son suficientes para ensamblar el genoma de *C. elegans*?
6. ¿Considera necesario aplicar un filtrado a las lecturas antes de proceder con el ensamble? En caso afirmativo, ¿qué tipo de filtro implementarían y cuál sería la justificación de su elección?
7. Observe el siguiente gráfico del “HTML report” y responda:
¿Observa algún pico en el número de reads para alguna longitud particular? ¿A qué podría corresponder?

Non weighted histogram of read lengths after log transformation



8. Por último, el siguiente resumen de información de parámetros principales corresponde al resultado obtenido del análisis de NanoPlot de la totalidad de los datos (corrida completa, 67 Gb), para que pueda comparar con su resultado del fastq_subsample (3,1 Gb):

```
GNU nano 2.9.3
General summary:
Mean read length:      21,442.2
Mean read quality:     16.9
Median read length:    11,621.0
Median read quality:   18.7
Number of reads:       3,123,358.0
Read length N50:       44,241.0
STDEV read length:     26,019.7
Total bases:           66,971,704,201.0
Number, percentage and megabases of reads above quality cutoffs
>Q10: 3080356 (98.6%) 66287.8Mb
>Q15: 2664898 (85.3%) 59708.6Mb
>Q20: 951782 (30.5%) 31281.4Mb
>Q25: 740 (0.0%) 9.1Mb
>Q30: 5 (0.0%) 0.1Mb
Top 5 highest mean basecall quality scores and their read lengths
1: 32.8 (836)
2: 31.2 (1385)
3: 31.2 (108338)
4: 31.0 (1389)
5: 30.3 (890)
Top 5 longest reads and their mean basecall quality score
1: 432774 (20.7)
2: 419558 (20.8)
3: 417164 (14.4)
4: 384650 (16.9)
5: 381368 (16.9)
```

Paso 3. Ensamble del genoma nuclear

Este paso se podría realizar con varias herramientas diferentes, la mayoría se basa en la estrategia de [OLC](#), como Miniasm, Canu o shasta entre otros.


Para este TP utilizaremos **HiFiasm**

(<https://github.com/chhy123/hifiasm/>, documentación = <https://hifiasm.readthedocs.io/en/latest/>).

Hifiasm puede emplearse para ensamblar a partir de lecturas ONT generadas con kits R10. Se recomienda utilizar un basecalling en modo super-accuracy y contar con una cobertura mínima de aproximadamente 30× en total (equivalente a ~15× por haplotipo). Bajo estas condiciones, es posible obtener dos ensamblajes diferenciados: el haplotipo primario y el alternativo.

Parámetros:

- *Assembly mode*: ONT



En la parte inferior de “**Advanced options**” (cambiar *leave default* por *specify* para desplegar opciones):

- *Estimated haploid genome size: 101m*
- *ONT read length cutoff: 1000 (dejar default)*
- *ONT base Quality Score cutoff = 10 (dejar default)*

Options for hifiasm scaffolding = Turn On Hifiasm Scaffolding

Output log file = Activado.

Estimated haploid genome size - optional

Estimated haploid genome size used for inferring read coverage. If not provided, this parameter will be inferred by hifiasm. Common suffices are required, for example, 100m or 3g (--hg-size)

ONT Read length cutoff - optional

Filter out ONT simplex reads shorter than specified length for assembly (--rl-cut)

ONT Base Quality Score cutoff - optional

Filter out ONT simplex reads with mean base quality score specified value for assembly (--sc-cut)

Options for hifiasm scaffolding

Output log file?

☒ Yes

Tiempo estimado de corrida desde el arranque: ~35 min.

39: Hifiasm on dataset 32: primary assembly contig graph for pseudohaplotype assembly

ok

Preview Visualize Details Edit

This dataset is large and only the first 1 MB is shown below.

Download

```
S ptg0000011
TTCCTTTACTCTATTTTGGCTTTTACAATATTTTATCTGATTGGCATTAGATTTTGATTAATTAACCTGAGAATGAAAAATAAT
GAAGAACTTCAATAATAATAAAATAAATTTTATATTTTCCGTTAATAGTTATTTCTATTATTAATTACTTTTCTAGTAA
AATATATTATTTCTGATAAGGTAAAGTCCAGTTGGGAGAGTAAGATGTAAATAGATATTACTATGTTGGTTACGGTCCA
AAAAGATGCACATCTTTGCGATCTAGTTTAGAAAAAATTTGTTTTGGTGCAAAAGAGTTTGATTGCATTAGTTTACTCTTTA
GTTTATAAATTAATATGGCCTGAAGAGGCTAAGAAATATTAGGAGTATTGAAATTAATAAGATTATTAATTTTGTAAAGGG
ATGTTGGTGACATTGCCATCTAGAAAAAATTTAACCATTAAAGATGAAATTTTGGTAGTATATTGGGTATAGTTTAACTCTTCAGATT
TTAACAGGTACATTTTAGCATTTTATTATACGCCGATAGGTTAATAGCATTTCACAGTGCAGTATATTATGATGAGGTAAAT
TTTGGATGAGTATTTGCAATTTTCAATTTTAAATGGGGCAGGTTATTTTATTTTGTGATTTACATATTTTAAAGGGTATTTT
TTTATAAGATATCGTTTAAAAAAGTATGATGCTCGGTTTAAACAAATTTATTTATAGTAATTAAGAGCTTTTATAGGTATGTT
TAGTTTGAAGCTCAATAAGATTTTGAAGCAGCATGTTTACTAGACTTTTAAAGATTATTTCCAATTGAGGGCCAACTATTGTT
ACTGAATTTGAAGAGTTTGGTTTACAGGGGCAACATTAAATCTTTTGTATTACATTTTATTGCGCTGAGCTATTCTA
GTTATTGTTTGGGGGCTTTAATTTTACACAGAGCTGTTAGAACATCTAGGTTATATTGCCACGGTGATTATGATAAGTTTGT
TTTAGACCTGAGTACTTAGGTAAAGATGCTATAATATTTGTTATTGATTATTATTATTGTTTAAAGGTTGATTACCCGTTTAA
TTAGGTGATGCGAGATGTTTATTGAAGCTGACCTATAATGAGGCCAGTTTCAATTGTTCCAGAGTGATATTTTATTGCTTAT
GCAATTTTGGTGCTATTTCCAAATAAGCTTAGGGGTAATTGCTTTATTAATAAGGATCGTAACATTTTATTTTGGCTTAGTT
AATAATTATACCTCTGTTTAAACAAATTAATAAATTTTAGTATTATATTATCTCATCTACTATTTTAAAGTGACTAGGT
```

> Historial

search datasets

Unnamed history

Default Storage

3.47 GB 19 32 4

☒ r pseudohaplotype assembly

39: Hifiasm on dataset 32: prim
ary assembly contig graph for
pseudohaplotype assembly

Add Tags

3,985 lines

formato gfa1, base de datos ?

```
5 ptg0000011 TTCCTTTACTCTATTTTGGCTTTT
ATGTTTGGTTACGGTCCAAAAGATGCACATCTTTGCGATCTAGTTT
GTATAGTTTAACTCTTCAGATTTTAAAGGTACATTTTAGCATTTT
```

Paso 4. Estadísticas del ensamblado

El ensamblador HiFiasm genera output en formato GFA (ver output “primary assembly contig graph for pseudohaplotype assembly”), por lo cual previamente se lo debe convertir a FASTA con la herramienta ‘GFA to FASTA’ para poder correr GFastats (2 min).

 **GFA to FASTA** ☆    

Convert Graphical Fragment Assembly files to FASTA format
(Galaxy Version 0.1.2)

Tool Parameters


Input GFA file *

39: Hifiasm on dataset 32: primary assembly contig graph for pseudohaplotype assembly ▼

accepted formats ▼

Una vez obtenido el ensamblado en formato FASTA se desea saber los valores de continuidad y calidad del ensamble, incluyendo N50, L50, AuN, N90 y/o L90. Para esto utilizaremos GFastats utilizando los parámetros por default (2 min).

 **gfastats** The swiss army knife for Genome Assembly ☆    

(Galaxy Version 1.3.11+galaxy2)

Tool Parameters

Input file *

46: GFA to FASTA on dataset 39: Fasta file ▼

accepted formats ▼

(--fasta)

Specify target sequences

Disabled ▼

Tool mode

Summary statistics generation ▼

Report mode

Genome assembly statistics (--nstar-report) ▼

47: gfastats on dataset 46: stats

ok

85 lines 2 columns, 7 comments

formato **tabular** base de datos ? size **1.8 KB**

Preview	Visualize	Details	Edit
# scaffolds	25		
Total scaffold length	106,076,602		
Average scaffold length	4,243,064.08		
Scaffold N50	18,550,341		
Scaffold auN	17,895,541.26		
Scaffold L50	3		
Largest scaffold	22,077,153		
Smallest scaffold	13,998		

1. ¿Cuántos scaffolds o contigs se obtuvieron en total? ¿Cómo se compara este número con la cantidad real de cromosomas del organismo (*C. elegans* posee 6)?
2. ¿Cuáles son los valores de N50 y L50 del ensamblado, y cómo deben interpretarse en conjunto?
3. ¿Cuál es el tamaño del scaffold más grande? ¿Es suficiente para representar un cromosoma completo por sí solo?

Paso 5. Evaluación de la completitud del ensamblado

Una de las metas principales de tener un genoma es establecer los genes presentes y su localización para continuar con otros análisis, como por ejemplo RNAseq.

Para tener un primer acercamiento se puede utilizar los genes curados en la base de datos [OrthoDB](#) y establecer la presencia de estos genes mediante [BUSCO](#) (5 min).

[OrthoDB](#) es una base de datos que agrupa genes que se conservan a lo largo de la evolución dentro de un mismo linaje taxonómico, por ejemplo, hay un set específico para nematodos, otro para plantas, otro para insectos. Estos son genes esenciales que casi todos los organismos de ese grupo tienen, típicamente en una sola copia.

[BUSCO](#) usa estos sets de OrthoDB como referencia: toma el listado de genes esperados para el linaje que elijan (por ejemplo, Nematoda para *C. elegans*) y busca cada uno de esos genes dentro del ensamble generado. Como resultado, informa cuántos aparecen completos, cuántos duplicados, cuántos fragmentados, y cuántos no se encontraron — dando así una medida de qué tan completo está el ensamble en términos de contenido génico.

Un valor de completos >80% es lo deseable y un valor >90% lo preferible. Este análisis se puede realizar a varios niveles taxonómicos, en el caso particular de *C. elegans* podría ser Eukaryota, Ecdysozoa, Nematoda y Rhabditida.

Parámetros:

- Sequence to analyse = ensamblado en formato FASTA (el mismo sobre el cual realizaron GFStats)
- Cached database with lineage: Busco v5 Linage Datasets (all+2024-03-21)
- Mode = genome assemblies
- Select a gene predictor = Miniprot
- Auto-detect or select lineage? = Select Lineage
- Lineage = **Nematoda**
- Which outputs should be generated = short summary text + summary image + gff

Tool Parameters

Sequences to analyse *



46: GFA to FASTA on dataset 23: Fasta file

accepted formats ▲

- fasta
- fasta.gz

Can be an assembled genome or transcriptome (DNA), or protein sequences

Cached database with lineage *

Busco v5 Lineage Datasets (all+2024-03-21)

Mode

Genome assemblies (DNA)

(--mode)

Select a gene predictor

Miniprot

In the case of a prokaryotic genome, Prodigal is the default gene predictor

Auto-detect or select lineage?

Select lineage

Let BUSCO decide the best lineage automatically, or select from known line


Lineage *

Nematoda

(--lineage_dataset)

Which outputs should be generated - optional

Short summary text ✕ Summary image ✕ gff ✕




1. ¿Qué porcentaje de genes esperados se encontraron completos (C)? ¿Supera el umbral de 80%?
2. ¿Cuántos genes totales tiene el set de referencia usado (n)?
3. ¿Qué porcentaje de los genes completos están duplicados (D)? Un valor alto de duplicados, ¿qué podría indicar sobre el ensamble (mala resolución de haplotipos, contaminación, o duplicación génica real)?
4. ¿Qué porcentaje de genes están fragmentados (F)? ¿Este valor es coherente con lo que vieron en GFStats sobre continuidad del ensamble (N50, número de contigs)?
5. ¿Qué porcentaje de genes falta por completo (M)? ¿A qué podría deberse — regiones del genoma que no se lograron secuenciar/ensamblar, o limitaciones del propio linaje de referencia usado?

Paso 6. Visualización del grafo de ensamblado nuclear con Bandage

Además de las tablas numéricas (assembly_info, GFAstats), es útil visualizar el grafo de ensamblado para identificar contigs circulares (candidatos a mitogenoma) y evaluar visualmente qué tan conectado/fragmentado quedó el genoma.

Bandage Image — genera una imagen del grafo

Herramienta: **Bandage Image**



Parámetros:

- **Input graph** = el archivo GFA a analizar

Run Tool.


Esto genera una imagen (PNG/SVG) del grafo de ensamblado. En la imagen:

- **Líneas largas y rectas** = contigs bien resueltos, sin ambigüedad.
- **Nodos que forman un círculo cerrado** = contigs circulares — candidatos a mitogenoma (o cloroplasto, en plantas).
- **Nudos o ramificaciones** = regiones ambiguas, típicamente repeticiones o zonas heterocigotas no resueltas.

Importante: esta es una imagen estática, no interactiva — no se puede hacer clic sobre los nodos para ver su información (longitud, cobertura), a diferencia de la aplicación de escritorio de Bandage.

Bandage Info — obtiene estadísticas del grafo en texto

Herramienta: **Bandage Info**



Parámetros:

- **Input graph** = el mismo archivo GFA

>Run Tool.

Devuelve un resumen en texto con estadísticas generales del grafo (número de nodos, número de links, N50). Si la herramienta lo permite, activar la opción de salida tabular (por ejemplo, `--tsv` o similar) para obtener el detalle por nodo individual (longitud y profundidad de cada segmento) — esto es lo que sirve para confirmar el tamaño exacto de un contig circular identificado en la imagen.

ANEXO. Pasos opcionales

Estimación del tamaño del genoma (Kmer)

En caso de realizarse un ensamble *de novo* y si se desconoce el tamaño esperado del genoma, se puede realizar el conteo de [kmers canónicos](#) en el set de datos de secuenciación.


Este proceso cuantifica kmers presentes en los datos y exige una tasa de error baja (<1% o <0.1%), por lo que solía restringirse a datos de Illumina, Pacbio HiFi y, más recientemente, a ONT dúplex.

Este proceso demanda unos 15 pasos, por lo que se les proveerá el archivo “Galaxy-Workflow-ONT-K-mer_profiling_and_QC_(WF1).ga” que automatiza el pipeline.



En la sección “flujos de trabajo” se puede importar este archivo y ejecutarlo.



El pipeline toma los datos de secuenciación, cuantifica los k-mers presentes, genera un histograma (cantidad de veces que cada k-mer se encontró en los datos) y luego estima estadísticamente el valor del tamaño del genoma, la cobertura, la duplicación y la heterocigosidad esperada. También grafica los datos mediante histogramas.



De este paso se obtienen gráficos similares a los siguientes:



[Merquy](#): Adicionalmente a BUSCO, se pueden utilizar los datos de k-mers calculados en el punto 3 para determinar si los mismos están o no presentes en el ensamble mediante [Merquy](#).

Parámetros:

- Evaluation mode = default mode
- K-mer counts database = Meryl (obtenido en el punto 3)
- Number of assemblies = One assembly
- Genome Assembly = output de Hifiasm (convertido a fasta) o Flye consensus
- Output:
 - QV stats
 - Plots
 - Stats files

Mercury evaluate the assembly quality (Galaxy Version: 1.3+galaxy3)

Tool Parameters

Evaluation mode

Default mode

Mercury allows two operational modes: default and trio mode.

K-mer counts database *

19: Meryl on data 5; read db:mergk10

Select the k-mer counts of the read set.

Number of assemblies

One assembly (pseudo-haplotype or mixed-haplotype)

Select the number of assemblies.

Genome assembly *

124: Flye on data 2; consensus

Select the assembled genome (FASTA).

Identification label optional

outout_mercury

Assign an identification label.

Output options optional

☒ Select / Deselect all

☒ QV stats

☒ Plots

☐ Size files

☒ Stats file

☐ BED hap-mer tracks

☐ WIG hap-mer tracks

☒ Histogram files

☐ Log file

Add column header on tabular outputs

☒ No


Additional Options

Email notification

☒ No

Send an email notification when the job completes.

Run Tool



Purge Dups: eliminar regiones de alta heterocigosis que generan 2 ensambles haplotípicos en lugar de un único haplotipo colapsado. [Link](#) de Galaxy workflow.

Scaffolding: generar secuencias más largas y completas a partir de un ensamble que puede realizarse a partir de las propias long-reads ([LINKS](#)), reads cortas de Illumina de tipo Hi-C ([Yahs](#), [SALSA2](#) o [3D-DNA](#)) o basadas en homología de especies filogenéticamente cercanas ([RagTag](#)), preferentemente del mismo género.

BlobToolKit= permite mostrar gráficos del tamaño de los segmentos (Contigs, scaffolds o cromosomas), %GC, ubicación de los genes, los resultados de BUSCO y permite detectar posible contaminación por simbiontes o contaminantes del laboratorio.

